

工作报告--罗佳佳

本周进度报告：可增删改查的离线金融知识库

✓ 本周进度

本周已完成一个可运行、可增删改查、可供 Agent 调用的离线知识库 MVP，并对 500 份金融监管附件完成全量摄取与检索验证。系统已具备解析器路由、版本化管理、结构化切块、混合检索、文件内二次检索、重排和引用溯源能力。当前完成的是“知识库与检索服务”，不是端到端自动问答产品；下一阶段重点是继续提升答案所在 Chunk 的召回质量，以及与 FinSage 完成 HTTP API 联动。

1. 本周任务与完成状态

搭建可增删改查的离线知识库 |  已完成 MVP | 知识库、文档、版本、Chunk 四层模型及管理 API/界面

完成多格式文件解析 |  已完成 | Excel、Word、PDF 轻量解析与解析器自动路由

引入 MinerU 处理复杂 PDF |  已完成全量验证 | MinerU 3.4.4；45/45 份 PDF 解析成功，最终按质量门禁选择解析器

完成 500 份资料初步建库 |  已完成并验收 | 499 个唯一文档，初始生成 24,189 个当前 Chunk

建立离线混合检索 |  已完成 | BM25、离线向量、RRF、轻量重排与引用返回

优化答案所在 Chunk 的命中 |  已有明显提升 | 严格证据单元召回由 33.13% 提升至 47.59%

与 FinSage 联动 |  接口方案已确定 | 离线知识库侧 API 已具备；FinSage HTTP 适配器待实现

端到端答案生成与无答案拒答 |  未完成 | 需要 FinSage/Agent 和可用的本地或受控 LLM |

2. 本周我完成的工作

2.1 可增删改查的知识库基础能力

- 知识库：创建、查询、修改、启停、归档和软删除；
- 文档：上传、批量导入、SHA-256 去重、启停、归档、删除和重新索引；
- 文档版本：新版本解析成功后再切换，失败时旧版本继续可用；
- Chunk：查询、人工修改、启停，并只更新被修改 Chunk 的向量；
- 任务与审计：记录解析、切块、索引、失败重试、取消、检索历史和管理操作；
- 管理界面：完成知识库、文档、版本、Chunk、任务和检索测试页面。

2.2 真实语料盘点与解析器路由

- 45 份 PDF 共 847 页，均有文本层；
- 31 份属于轻量解析候选，14 份属于复杂版面/MinerU 候选；
- 安装 MinerU 3.4.4 和完整 pipeline 模型；
- 使用 MinerU 完成 45/45 份 PDF 全量解析和 A/B 复核，最终生产版本为 18 份 MinerU、27 份 Lightweight；
- MinerU 不可用或解析失败时会记录尝试链并自动回退，不会阻塞整个建库流程；
- Docling 尚未安装，保留为后续可选解析器。

2.3 完成全量建库与离线索引

- 500 个源文件中发现 1 组 SHA-256 完全重复文件；
- 最终得到 499 个唯一文档与 499 个有效版本；
- 初始全量摄取生成 24,189 个当前 Chunk 和对应向量，失败 0；
- 对 45 份 PDF 完成 MinerU 重切块、向量化和版本选择后，最终快照为 21,725 个 Chunk/向量；
- Chunk 数量下降来自解析与切块规则调整，不代表文档丢失，最终快照仍包含 499 个文档；
- 默认 hashing embedding 完全离线，可在不下载模型、不启动外部向量服务的情况下运行；
- 同时保留切换本地 sentence-transformers 和 Qdrant 的扩展能力。

2.4 完成检索 API 与 Agent 接口

操作	API			
新增	POST /api/knowledge-bases			
查询列表	GET /api/knowledge-bases			
查询详情	GET /api/knowledge-bases/{id}			
修改	PUT /api/knowledge-bases/{id}			
启用/停用	POST /enable 、 POST /disable			
归档	POST /archive			
删除	DELETE /api/knowledge-bases/{id}			
上传文档	POST /api/knowledge-bases/{kb_id}/documents			
查询文档列表	GET /api/knowledge-bases/{kb_id}/documents			
查询文档详情	GET /api/documents/{document_id}			
修改标题或元数据	PUT /api/documents/{document_id}			
上传新版本	POST /api/documents/{document_id}/versions			

操作	API			
查询版本	GET /api/documents/{document_id}/versions			
激活历史版本	POST /api/versions/{version_id}/activate			
重建索引	POST /api/documents/{document_id}/reindex			
启用/停用	POST /enable 、 POST /disable			
删除	DELETE /api/documents/{document_id}			
新增	POST /api/documents/{document_id}/chunks			
查询列表	GET /api/documents/{document_id}/chunks			
查询详情	GET /api/chunks/{chunk_id}			
修改	PUT /api/chunks/{chunk_id}			
启用/停用	POST /enable 、 POST /disable			
删除	DELETE /api/chunks/{chunk_id}			

已经提供稳定的 REST 接口供 Agent 或 FinSage 调用：

POST /api/retrieval/search

POST /api/retrieval/documents/{document_id}/search

接口可以返回：

- 命中 Chunk 正文与分数；
- 文件名、页码和章节；
- document_id 与 chunk_id；
- 邻接上下文 metadata.context；
- 第一阶段文档候选 document_candidates。

第二个接口用于 Agent 已经选定文件后的文件内二次检索。

2.5 完成检索评测与指标口径澄清

我完成了一组真实 API 评测：

QA数据.xlsx 选择题开发集

- 原始 300 题，去除 22 道完全重复题后按 278 题统计；
- 覆盖 Excel、Word、PDF 共 48 个来源文件；
- 题干明确包含来源标题且四个选项也参与检索，因此属于“标题+选项条件下的检索评测”，不是开放式问答。

3. 遇到的问题、分析与解决方式

3.1 问题：能找到目标文件，但不一定找到答案所在 Chunk

初始评测中，目标来源文件 Hit@6 已达到 91.73%，但严格证据单元召回只有 47.59%。这说明第一阶段经常能找到正确文件，第二阶段返回的前几个 Chunk 却不一定包含金标答案对应的完整文本或数值。

④ 47.59%的准确含义

该指标检查“金标证据文本/数值是否完整出现在目标文件返回的 Chunk 中”。它不是答案正确率，也不表示只有 47.59% 的文件被找到。文件可能已经召回，但答案位于同文件的其他 Chunk；另外，文本改写、单位换算或 Excel 显示精度差异也会被严格词面指标标记为未覆盖。

主要原因包括：

- 初始检索在全库平铺排序，长文档或高频词文档容易占据多个位置；
- 题目中的来源标题与四个选项会干扰真正的正文证据检索；
- 表格切块没有充分重复表名、单位和列表头，单独一行缺少语义；
- PDF/Word 中短行标题误判、条款边界和上下文断裂影响答案定位；
- 单个文档返回过多相似 Chunk，挤占其他有效证据；
- 严格词面评测对同义改写和数值格式非常保守。

3.2 已完成的检索改进

我完成了以下优化：

1. 增加标题、扩展名、附件号和结构化编号的文档路由；
2. 增加文件内 BM25/向量二次检索，避免全库 Chunk 一次性竞争；
3. 使用 RRF 融合多路召回，并增加本地轻量重排；
4. 对每个文档设置硬性 Chunk 上限，降低长文档结果垄断；
5. 优化法规条款切分、PDF 短行正文回流和表格结构化切块；
6. 表格 Chunk 重复表名、单位和语义表头，并增加表行重叠；
7. 保存 parent_id、同级顺序和前后逻辑 Chunk 指针；
8. 对命中 Chunk 增加同父组、同章节的邻接上下文，但不占用 top_k；
9. 增加有界 BM25 缓存，降低重复检索延迟；
10. 对 45 份 PDF 完成 MinerU 重建，并按质量和检索回归结果选择最终版本。

3.3 尚未完全解决的问题

PDF/Word 严格证据单元召回仍偏低（PDF 15.84%，Word 21.21%）
补页码/条款级金标，优化层级切块并定向重建索引

4. 与 FinSage 的联动方案

采用 API 解耦。

FinSage 侧主要需要增加

- ☐ 新增 OfflineKnowledgeRetriever HTTP 检索适配器；
- ☐ 增加 KNOWLEDGE_API_URL、KNOWLEDGE_API_KEY、超时和 top_k 配置；
- ☐ 调用 /api/retrieval/search，已确定文件时调用文件内二次检索接口；
- ☐ 将知识库返回结果映射为 FinSage 使用的 RAG Chunk；
- ☐ 完整保留文件名、页码、章节、document_id 和 chunk_id；
- ☐ 增加超时、重试、熔断和知识库不可用时的明确降级提示；
- ☐ 修改提示词：只能根据检索证据回答，证据不足时澄清或拒答；
- ☐ 配置可用的大模型 API Key 或本地模型，完成答案生成；
- ☐ 对 FinSage 的 /api/rag/ 与比赛专用 /api/competition/ 做清晰分工，避免接口语义混淆。

5. 后续完善计划

P0：先完成可稳定演示的端到端链路

- ☐ 与 FinSage HTTP 适配器联调；
- ☐ 使用 10 道代表性问题验证“检索—生成—引用”全链路；

P1：继续提高答案 Chunk 的可用性

- ☐ 按 PDF、Word、Excel 分格式分析失败题，避免只看总指标；
- ☐ 为 PDF/Word 补充页码、条款和 Chunk 级人工金标；
- ☐ 建立“文档 → 章/节/条 → 款/句”和“工作表 → 表格 → 行/单元格组”层级；
- ☐ 评估基于子块覆盖率的父块合并，控制上下文长度；
- ☐ 在完全离线前提下评估中文本地 CrossEncoder 重排模型；
- ☐ 增加精确数值、单位换算、跨期比较和结构化 Excel 求解；
- ☐ 加入无答案题，验证系统能拒答而不是强行拼接。

P2：补齐解析器与工程化验证

- ☐ 评估 Docling 作为备用解析器，不把安装状态写成已实现效果；
- ☐ 增加 API 压测、并发测试、异常恢复和监控；
- ☐ 完成第三方依赖许可证清单与离线模型交付说明。


6. 需要的协作与帮助

- 实现 HTTP 检索适配器、证据注入、引用显示、超时降级和提示词约束，使 FinSage 能自主调用离线知识库并基于证据回答；
- 将 knowledge_search 注册为工具，管理 document_id 和文件内追问状态，使 Agent 能完成“先找文件、再找证据”的两阶段检索。

7. 总结

- 已完成可增删改查的离线金融知识库 MVP；
- 已对 500 份真实资料完成全量摄取验证，得到 499 个唯一文档；
- 已实现解析路由、结构化切块、混合检索、文件内二次检索、重排和引用溯源；
- 已使用 MinerU 完成 45/45 份 PDF 全量解析，并通过 A/B 选择 18 份 MinerU、27 份 Lightweight；
- QA数据.xlsx 的目标来源文件 Hit@6 已提升到 100%，严格证据单元召回由 33.13% 提升到 47.59%；
- 已提供可供 Agent/FinSage 调用的离线检索 REST API。

当前知识库支持四层增删改查：



当前 API 地址：`http://127.0.0.1:8001/api`
当前知识库 ID：`cd77f9a9-07c2-4204-8e53-6d59b7c2a2d6`
可在 `http://127.0.0.1:8001/docs` 直接操作。

一、怎么增删改查

1. 知识库

操作	API
新增	POST /api/knowledge-bases
查询列表	GET /api/knowledge-bases
查询详情	GET /api/knowledge-bases/{id}
修改	PUT /api/knowledge-bases/{id}
启用/停用	POST /enable 、 POST /disable
归档	POST /archive
删除	DELETE /api/knowledge-bases/{id}

新增示例：

```
curl -X POST http://127.0.0.1:8001/api/knowledge-bases \
-H "Content-Type: application/json" \
-d '{
```

```
"name": "测试知识库",
"description": "用于测试",
"retrieval_config": {}
}'
```

2. 文档

操作	API
上传文档	POST /api/knowledge-bases/{kb_id}/documents
查询文档列表	GET /api/knowledge-bases/{kb_id}/documents
查询文档详情	GET /api/documents/{document_id}
修改标题或元数据	PUT /api/documents/{document_id}
上传新版本	POST /api/documents/{document_id}/versions
查询版本	GET /api/documents/{document_id}/versions
激活历史版本	POST /api/versions/{version_id}/activate
重建索引	POST /api/documents/{document_id}/reindex
启用/停用	POST /enable 、 POST /disable
删除	DELETE /api/documents/{document_id}

上传文件：

```
curl -X POST \
  http://127.0.0.1:8001/api/knowledge-bases/cd77f9a9-07c2-4204-8e53-6d59b7c2a2d6/documents \
  -F "files=@测试文件.pdf" \
  -F "parser=auto" \
  -F "auto_enable=true"
```

parser 可选：

- auto
- lightweight
- mineru
- docling

修改标题和元数据：

```
curl -X PUT http://127.0.0.1:8001/api/documents/文档ID \
  -H "Content-Type: application/json" \
  -d '{
    "title": "修改后的标题",
    "metadata": {
```

```
"year": "2025",
"document_type": "regulation"
}
}'
```

文档正文文件不能通过这个接口直接覆盖。需要修改源文件时，应上传一个新版本，解析成功后系统才会切换。

3. Chunk

操作	API
新增	POST /api/documents/{document_id}/chunks
查询列表	GET /api/documents/{document_id}/chunks
查询详情	GET /api/chunks/{chunk_id}
修改	PUT /api/chunks/{chunk_id}
启用/停用	POST /enable 、 POST /disable
删除	DELETE /api/chunks/{chunk_id}

修改Chunk：

```
curl -X PUT http://127.0.0.1:8001/api/chunks/ChunkID \
-H "Content-Type: application/json" \
-d '{
  "content": "人工修改后的正文",
  "page_number": 12,
  "section": "第三章 第十二条",
  "enabled": true
}'
```

修改Chunk正文后，系统会自动重新生成该Chunk的向量，不需要重建整份文档。

4. 检索查询

全库检索：

```
POST /api/retrieval/search
```

文件内二次检索：

```
POST /api/retrieval/documents/{document_id}/search
```

二、知识库内部字段

KnowledgeBase字段

字段	含义
id	知识库唯一ID
name	知识库名称
description	描述
status	active、disabled或archived
enabled	是否启用
archived	是否归档
embedding_model	当前Embedding模型
retrieval_config	检索配置JSON
document_count	文档数量
chunk_count	当前Chunk数量
created_at 、 updated_at	创建和更新时间

Document字段

字段	含义
id	文档ID
knowledge_base_id	所属知识库
title	文档标题
file_name	原文件名
content_type	MIME类型
file_size	文件大小
file_hash	SHA-256，用于去重
status	处理状态
enabled	是否参加检索
archived	是否归档
current_version_id	当前生效版本
version_number	当前版本号
parser	实际解析器
page_count	页数
chunk_count	Chunk数量
metadata	扩展元数据
error_message	失败信息

字段	含义
created_at 、 updated_at	时间

默认文档元数据包括：

- year
- document_type
- file_extension
- content_type

其中 document_type 通常为：

- report
- statistics
- regulation
- attachment

DocumentVersion字段

字段	含义
id	版本ID
document_id	所属文档
version_number	版本号
file_name	版本文件名
file_hash	版本文件哈希
parser	使用的解析器
status	解析状态
is_current	是否为当前版本
page_count	页数
chunk_count	Chunk数量
processing_started_at	开始处理时间
processing_completed_at	完成时间
error_message	失败原因

Chunk字段

字段	含义
id	Chunk ID

字段	含义
document_id	所属文档
version_id	所属版本
chunk_index	在文档中的顺序
content	Chunk正文
content_hash	正文哈希
token_count	Token数量
page_number	页码
section	章节或条款
status	active、disabled或删除
enabled	是否参加检索
manually_edited	是否人工修改
metadata	父子关系、邻接关系、表格等扩展信息
created_at 、 updated_at	时间

删除操作默认是软删除。临时不想让数据参加检索时，建议使用“停用”而不是直接删除。

三、QA数据.xlsx的字段

[QA数据.xlsx](#) 共有300条数据、15个字段：

字段	含义
id	题目ID， 如Q001
source_type	来源类型： excel、 word、 pdf
difficulty	easy、 medium、 hard
difficulty_cn	简单、中等、困难
qa_type	题目类型
question	题干
option_a ~ option_d	四个选项
answer	正确选项A/B/C/D
answer_text	正确答案正文
evidence	标准证据文本或表格坐标
source_title	来源资料标题
file_label	对应源文件名

qa_type 包括：

- 单事实检索
- 多事实检索
- 表格取数
- 表格比较
- 表格计算